# 加微信:642945106 发送"赠送"领取赠送精品课程

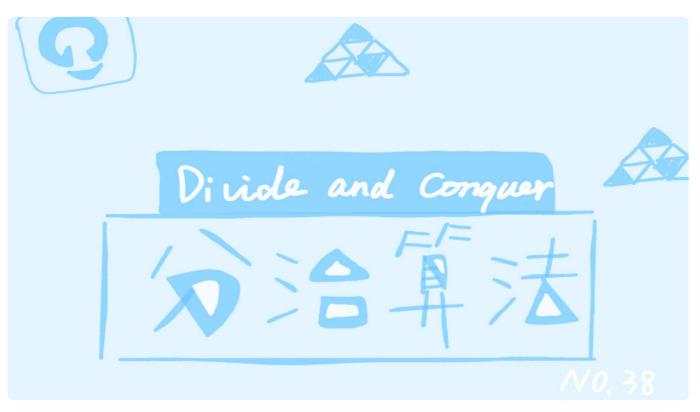
■ 发数字"2"获取众筹列表

「载APP (

# 38 | 分治算法:谈一谈大规模计算框架MapReduce中的分治思想

2018-12-19 王争

数据结构与算法之美 进入课程>



讲述:修阳

时长 11:47 大小 10.80M



MapReduce 是 Google 大数据处理的三驾马车之一,另外两个是 GFS 和 Bigtable。它在 倒排索引、PageRank 计算、网页分析等搜索引擎相关的技术中都有大量的应用。

尽管开发一个 MapReduce 看起来很高深,感觉跟我们遥不可及。实际上,万变不离其宗,它的本质就是我们今天要学的这种算法思想,分治算法。

# 如何理解分治算法?

为什么说 MapRedue 的本质就是分治算法呢?我们先来看,什么是分治算法?

分治算法 (divide and conquer)的核心思想其实就是四个字,分而治之,也就是将原问题划分成 n 个规模较小,并且结构与原问题相似的子问题,递归地解决这些子问题,然后

再合并其结果,就得到原问题的解。

这个定义看起来有点类似递归的定义。关于分治和递归的区别,我们在排序(下)的时候讲过,**分治算法是一种处理问题的思想,递归是一种编程技巧**。实际上,分治算法一般都比较适合用递归来实现。分治算法的递归实现中,每一层递归都会涉及这样三个操作:

分解:将原问题分解成一系列子问题;

解决:递归地求解各个子问题,若子问题足够小,则直接求解;

合并:将子问题的结果合并成原问题。

分治算法能解决的问题,一般需要满足下面这几个条件:

原问题与分解成的小问题具有相同的模式;

原问题分解成的子问题可以独立求解,子问题之间没有相关性,这一点是分治算法跟动态规划的明显区别,等我们讲到动态规划的时候,会详细对比这两种算法;

具有分解终止条件,也就是说,当问题足够小时,可以直接求解;

可以将子问题合并成原问题,而这个合并操作的复杂度不能太高,否则就起不到减小算法总体复杂度的效果了。

# 分治算法应用举例分析

理解分治算法的原理并不难,但是要想灵活应用并不容易。所以,接下来,我会带你用分治算法解决我们在讲排序的时候涉及的一个问题,加深你对分治算法的理解。

还记得我们在排序算法里讲的数据的有序度、逆序度的概念吗?我当时讲到,我们用有序度来表示一组数据的有序程度,用逆序度表示一组数据的无序程度。

假设我们有 n 个数据, 我们期望数据从小到大排列, 那完全有序的数据的有序度就是 n(n-1)/2, 逆序度等于 0; 相反, 倒序排列的数据的有序度就是 0, 逆序度是 n(n-1)/2。除了这两种极端情况外, 我们通过计算有序对或者逆序对的个数, 来表示数据的有序度或逆序度。

# 2,4,3,1、5,6 逆序对个数:4 (2,1)(4,3)(4,1)(3,1)

我现在的问题是,**如何编程求出一组数据的有序对个数或者逆序对个数呢**?因为有序对个数 和逆序对个数的求解方式是类似的,所以你可以只思考逆序对个数的求解方法。

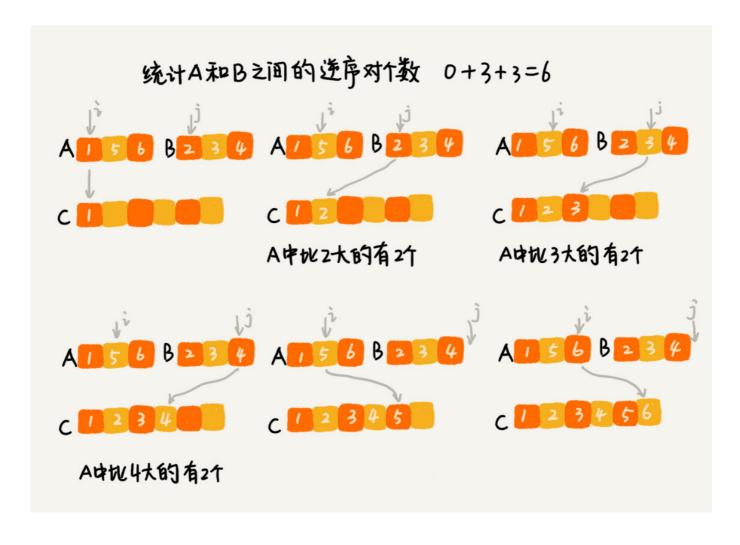
最笨的方法是,拿每个数字跟它后面的数字比较,看有几个比它小的。我们把比它小的数字个数记作 k,通过这样的方式,把每个数字都考察一遍之后,然后对每个数字对应的 k 值求和,最后得到的总和就是逆序对个数。不过,这样操作的时间复杂度是 O(n^2)。那有没有更加高效的处理方法呢?

我们用分治算法来试试。我们套用分治的思想来求数组 A 的逆序对个数。我们可以将数组分成前后两半 A1 和 A2,分别计算 A1 和 A2 的逆序对个数 K1 和 K2,然后再计算 A1 与 A2 之间的逆序对个数 K3。那数组 A 的逆序对个数就等于 K1+K2+K3。

我们前面讲过,使用分治算法其中一个要求是,子问题合并的代价不能太大,否则就起不了降低时间复杂度的效果了。那回到这个问题,如何快速计算出两个子问题 A1 与 A2 之间的 逆序对个数呢?

这里就要借助归并排序算法了。你可以先试着想想,如何借助归并排序算法来解决呢?

归并排序中有一个非常关键的操作,就是将两个有序的小数组,合并成一个有序的数组。实际上,在这个合并的过程中,我们就可以计算这两个小数组的逆序对个数了。每次合并操作,我们都计算逆序对个数,把这些计算出来的逆序对个数求和,就是这个数组的逆序对个数了。



尽管我画了张图来解释,但是我个人觉得,对于工程师来说,看代码肯定更好理解一些,所以我们把这个过程翻译成了代码,你可以结合着图和文字描述一起看下。

■ 复制代码

```
1 private int num = 0; // 全局变量或者成员变量
3 public int count(int[] a, int n) {
   num = 0;
    mergeSortCounting(a, 0, n-1);
    return num;
7 }
9 private void mergeSortCounting(int[] a, int p, int r) {
   if (p >= r) return;
   int q = (p+r)/2;
11
    mergeSortCounting(a, p, q);
    mergeSortCounting(a, q+1, r);
    merge(a, p, q, r);
14
15 }
17 private void merge(int[] a, int p, int q, int r) {
   int i = p, j = q+1, k = 0;
    int[] tmp = new int[r-p+1];
   while (i<=q && j<=r) \{
20
```

```
if (a[i] <= a[j]) {
       tmp[k++] = a[i++];
      } else {
       num += (q-i+1); // 统计 p-q 之间, 比 a[j] 大的元素个数
        tmp[k++] = a[j++];
     }
27
    while (i <= q) { // 处理剩下的
    tmp[k++] = a[i++];
30
    while (j <= r) { // 处理剩下的
31
    tmp[k++] = a[j++];
32
33
    for (i = 0; i <= r-p; ++i) { // 从 tmp 拷贝回 a
    a[p+i] = tmp[i];
36
  }
37 }
```

有很多同学经常说,某某算法思想如此巧妙,我是怎么也想不到的。实际上,确实是的。有些算法确实非常巧妙,并不是每个人短时间都能想到的。比如这个问题,并不是每个人都能想到可以借助归并排序算法来解决,不夸张地说,如果之前没接触过,绝大部分人都想不到。但是,如果我告诉你可以借助归并排序算法来解决,那你就应该要想到如何改造归并排序,来求解这个问题了,只要你能做到这一点,我觉得就很棒了。

关于分治算法,我这还有两道比较经典的问题,你可以自己练习一下。

二维平面上有 n 个点,如何快速计算出两个距离最近的点对?

有两个 n\*n 的矩阵 A, B, 如何快速求解两个矩阵的乘积 C=A\*B?

### 分治思想在海量数据处理中的应用

分治算法思想的应用是非常广泛的,并不仅限于指导编程和算法设计。它还经常用在海量数据处理的场景中。我们前面讲的数据结构和算法,大部分都是基于内存存储和单机处理。但是,如果要处理的数据量非常大,没法一次性放到内存中,这个时候,这些数据结构和算法就无法工作了。

比如,给 10GB 的订单文件按照金额排序这样一个需求,看似是一个简单的排序问题,但是因为数据量大,有 10GB,而我们的机器的内存可能只有 2、3GB 这样子,无法一次性加载到内存,也就无法通过单纯地使用快排、归并等基础算法来解决了。

要解决这种数据量大到内存装不下的问题,我们就可以利用分治的思想。我们可以将海量的数据集合根据某种方法,划分为几个小的数据集合,每个小的数据集合单独加载到内存来解决,然后再将小数据集合合并成大数据集合。实际上,利用这种分治的处理思路,不仅仅能克服内存的限制,还能利用多线程或者多机处理,加快处理的速度。

比如刚刚举的那个例子,给 10GB 的订单排序,我们就可以先扫描一遍订单,根据订单的金额,将 10GB 的文件划分为几个金额区间。比如订单金额为 1 到 100 元的放到一个小文件,101 到 200 之间的放到另一个文件,以此类推。这样每个小文件都可以单独加载到内存排序,最后将这些有序的小文件合并,就是最终有序的 10GB 订单数据了。

如果订单数据存储在类似 GFS 这样的分布式系统上,当 10GB 的订单被划分成多个小文件的时候,每个文件可以并行加载到多台机器上处理,最后再将结果合并在一起,这样并行处理的速度也加快了很多。不过,这里有一个点要注意,就是数据的存储与计算所在的机器是同一个或者在网络中靠的很近(比如一个局域网内,数据存取速度很快),否则就会因为数据访问的速度,导致整个处理过程不但不会变快,反而有可能变慢。

你可能还有印象,这个就是我在讲线性排序的时候举的例子。实际上,在前面已经学习的课程中,我还讲了很多利用分治思想来解决的问题。

# 解答开篇

分治算法到此就讲完了,我们现在来看下开篇的问题,为什么说 MapReduce 的本质就是分治思想?

我们刚刚举的订单的例子,数据有 10GB 大小,可能给你的感受还不强烈。那如果我们要处理的数据是 1T、10T、100T 这样子的,那一台机器处理的效率肯定是非常低的。而对于谷歌搜索引擎来说,网页爬取、清洗、分析、分词、计算权重、倒排索引等等各个环节中,都会面对如此海量的数据(比如网页)。所以,利用集群并行处理显然是大势所趋。

一台机器过于低效,那我们就把任务拆分到多台机器上来处理。如果拆分之后的小任务之间 互不干扰,独立计算,最后再将结果合并。这不就是分治思想吗?

实际上, MapReduce 框架只是一个任务调度器, 底层依赖 GFS 来存储数据, 依赖 Borg 管理机器。它从 GFS 中拿数据, 交给 Borg 中的机器执行, 并且时刻监控机器执行的进度, 一旦出现机器宕机、进度卡壳等, 就重新从 Borg 中调度一台机器执行。

尽管 MapReduce 的模型非常简单,但是在 Google 内部应用非常广泛。它除了可以用来处理这种数据与数据之间存在关系的任务,比如 MapReduce 的经典例子,统计文件中单词出现的频率。除此之外,它还可以用来处理数据与数据之间没有关系的任务,比如对网页分析、分词等,每个网页可以独立的分析、分词,而这两个网页之间并没有关系。网页几十亿、上百亿,如果单机处理,效率低下,我们就可以利用 MapReduce 提供的高可靠、高性能、高容错的并行计算框架,并行地处理这几十亿、上百亿的网页。

### 内容小结

今天我们讲了一种应用非常广泛的算法思想,分治算法。

分治算法用四个字概括就是"分而治之",将原问题划分成 n 个规模较小而结构与原问题相似的子问题,递归地解决这些子问题,然后再合并其结果,就得到原问题的解。这个思想非常简单、好理解。

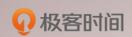
今天我们讲了两种分治算法的典型的应用场景,一个是用来指导编码,降低问题求解的时间复杂度,另一个是解决海量数据处理问题。比如 MapReduce 本质上就是利用了分治思想。

我们也时常感叹 Google 的创新能力如此之强,总是在引领技术的发展。实际上,创新并非离我们很远,创新的源泉来自对事物本质的认识。无数优秀架构设计的思想来源都是基础的数据结构和算法,这本身就是算法的一个魅力所在。

### 课后思考

我们前面讲过的数据结构、算法、解决思路,以及举的例子中,有哪些采用了分治算法的思想呢?除此之外,生活、工作中,还有没有其他用到分治算法的地方呢?你可以自己回忆、总结一下,这对你将零散的知识提炼成体系非常有帮助。

欢迎留言和我分享,也欢迎点击"请朋友读",把今天的内容分享给你的好友,和他一起讨论、学习。



# 数据结构与算法之美

为工程师量身打造的数据结构与算法私教课

王争

前 Google 工程师



新版升级:点击「 🍣 请朋友读 」,10位好友免费读,邀请订阅更有现金奖励。

© 版权归极客邦科技所有,未经许可不得传播售卖。 页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 37 | 贪心算法:如何用贪心算法实现Huffman压缩编码?

下一篇 不定期福利第三期 | 测一测你的算法阶段学习成果

### 精选留言 (44)



**心** 8



Williamzh... 置顶 2018-12-20

第一个留言有问题可以再理解一下,不要误导后边人,作者的num+=语句位置正确

作者回复: 哈哈 终于有人看懂了 我的跟留言那位同学的思路不一样而已 他的更简洁些



三木子

ሰን 14

在统计方面比较多,比如统计我国人口,要知道我国人口就要先知道每个省人口,要知道 省人口就要知道每个市人口,要知道市人口就要知道每个区县人口,直到村社区,然后汇 总求的总人数。

作者回复: 凸

 $\triangleleft$ 



凸 10

老师,我有两个疑问:

给 10GB 的订单排序, 我们就可以先扫描一遍订单

\_\_\_\_\_

1.场景中描述的机器内存只有2、3GB, 我理解的是直接加载文件内存应该不够用来扫描一次10GB订单文件, 对吗?如果不能, 那应该怎么扫描呢?...

展开٧

**我爱** 刘远通 学习 2018-12-20 心 7

第一个求最近的点对

分成两块 单独求其中一块点对最小距离

然后求这两块之间点对的最小距离 通过一些排序和删除 可以减少到6个点之间比较 很神奇

第二个矩阵计算...

展开٧



凸 6

把归并排序merge方法的参数列表 由merge(int[] a, int p, int q, int r) 改为 merge(int[] a, int low, int middle, int high) 更容易理解 ( ) 小细节,哈哈 展开 >

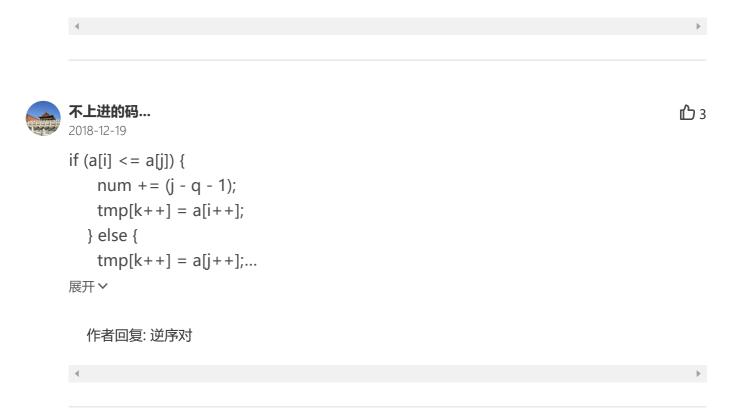
**Yves** 2018-12-19

凸 6

代码略有问题:1 , num += (q - i + 1) , 应该是在 a[i] <= a[j] 这个条件分支里面;2 , while (i <= q) 里面不应该有 num += (q - i + 1) , 3 , 最后的修改原数组迭代条件应该是 i < r - p + 1 而不是 i < r - p 。

private void merge(int[] a, int p, int q, int r) {... 展开~

作者回复: 是的 大家代码直接看这位同学的 我晚点改正下。写的时候匆忙 不好意思





**L** 2

分治算法本质上就是利用多核cpu并行计算能力,如果只是单核cpu,分治算法是不是就不可行了?

作者回复: 不。单核也可以利用多线程并行。毕竟一般的算法代码都包括: 内存访问、CPU计算两部分,并不只是CPU计算。

**Sharry** 2018-12-20

**ြ** 2

使用归并排序求逆序度,实在是太妙了! 老师的代码一点儿问题都没有, (j-q-1) 记录的是比子序列 A 中当前即将添加到 tmp 数组中的元素的逆序对的个数,看到留言里小伙伴说应该放在下面的 else 里,可能需要再斟酌斟酌



「创新并非离我们很远,创新的源泉来自对事物本质的认识。无数优秀架构设计的思想来 源都是基础的数据结构和算法,这本身就是算法的一个魅力所在。|

这句话讲的太好啦。各种前端框架层出不穷,本质的东西,也是基本都没有变。

展开٧



凸 1

老师, 求有(逆)序对只需一遍扫描即可, O(n)就能解决, 所以用归并排序求解的这个例子并 不太合适。

作者回复: 怎么搞定的呢?貌似不行吧



凸 1

leetcode 315

展开٧



**ALAN** 

凸 1

老师,你好,有一个建议,就是对于代码每一行里不是很显然易懂的地方,能否注释下此 行代码的作用,不然有时看了代码也不知为啥这样写。

展开٧



刘冬

凸

王老师, 我觉得利用merge sort找逆序对个数的代码, 最后3行, 就是讲tmp[]拷贝回a[]这 个操作,应该是不需要的。在排序过程中,tmp[]是有序的,a[]是不变的。那么partition 之后,应该使用原始的数组一份而二的2个子数组来分别找各自的逆序对。应该用原始的数 据。tmp[]拷贝之后,对有序的做判断,值为0。实际上,我觉得根本就不需要tmp[]这个 辅助数组。...

展开~

作者回复: 你理解的有点问题, 你可以自己举几个例子, debug一下看下。





打卡学习

展开٧

# 创新的源泉来自对事物本质的认识

展开~



2019-03-08

ம

逆序对 我参考楼主 用c 实现了一个

1 #include <stdio.h>

2

3 int merge(int a[], int s, int mid, int d)

4 {...

展开~